

# Comparison between GPT-4 and GPT-4o Mini

This figure presents a comparison between GPT-4 and GPT-4o Mini in the context of a customer support AI agent.

The comparison was somewhat challenging because both models showed generally good performance and were able to answer most questions correctly. However, GPT-4 demonstrated more consistent and reliable behavior overall.

| id | model | question    | expected                                       | lang_expected              | lang_answer | lang_ok | policy_ok | latency_ms | answer_preview                                     |
|----|-------|-------------|------------------------------------------------|----------------------------|-------------|---------|-----------|------------|----------------------------------------------------|
| 0  | 1     | gpt-4o-mini | بدي أرجع هتمة عليها تخفيض                      | discount_no_return         | ar          | ar      | True      | 0          | لا، المنتجات المخفضة أو التي ضمن العروض غير فا     |
| 1  | 1     | gpt-4o      | بدي أرجع هتمة عليها تخفيض                      | discount_no_return         | ar          | ar      | True      | 0          | لا، المنتجات المخفضة أو التي ضمن العروض غير فا     |
| 2  | 2     | gpt-4o-mini | Can I return discounted items?                 | discount_no_return         | en          | en      | True      | 0          | No. Discounted or promotional items are not re...  |
| 3  | 2     | gpt-4o      | Can I return discounted items?                 | discount_no_return         | en          | en      | True      | 0          | No. Discounted or promotional items are not re...  |
| 4  | 3     | gpt-4o-mini | استلمت الطلب قبل 3 أيام وبدي أرجعه             | after_48_no_return         | ar          | ar      | True      | 2644       | ... لإرجاع الطلب، يجب أن يتم ذلك خلال 48 ساعة من ا |
| 5  | 3     | gpt-4o      | استلمت الطلب قبل 3 أيام وبدي أرجعه             | after_48_no_return         | ar          | ar      | True      | 2546       | للأسف، سياسة المتجر تلزم على أن الإرجاع مسموح      |
| 6  | 4     | gpt-4o-mini | استلمت القطعة اليوم وفيها عيب، بقدر أرجعها؟    | defect_ok_within_48        | ar          | ar      | True      | 1478       | ... نعم، يمكنك طلب إرجاع القطعة إذا كانت تحتوي على |
| 7  | 4     | gpt-4o      | استلمت القطعة اليوم وفيها عيب، بقدر أرجعها؟    | defect_ok_within_48        | ar          | ar      | True      | 1980       | ... نعم، يمكنك إرجاع القطعة إذا كانت تحتوي على عيب |
| 8  | 5     | gpt-4o-mini | المقاس طلع صغير، شو الحل؟                      | size_ok_within_48          | ar          | ar      | True      | 1733       | يمكنك طلب إرجاع القطعة خلال 48 ساعة من             |
| 9  | 5     | gpt-4o      | المقاس طلع صغير، شو الحل؟                      | size_ok_within_48          | ar          | ar      | True      | 2034       | يمكنك طلب إرجاع القطعة خلال 48 ساعة من             |
| 10 | 6     | gpt-4o-mini | بدي أغي الطلب وهو طالع للتوصيل                 | no_cancel_out_for_delivery | ar          | ar      | True      | 0          | ... لا يمكن إلغاء الطلب أو رفض استلامه بعد خروجه ل |
| 11 | 6     | gpt-4o      | بدي أغي الطلب وهو طالع للتوصيل                 | no_cancel_out_for_delivery | ar          | ar      | True      | 0          | ... لا يمكن إلغاء الطلب أو رفض استلامه بعد خروجه ل |
| 12 | 7     | gpt-4o-mini | My order is out for delivery, can I cancel it? | no_cancel_out_for_delivery | en          | en      | True      | 0          | You can't cancel or refuse an order once it is...  |
| 13 | 7     | gpt-4o      | My order is out for delivery, can I cancel it? | no_cancel_out_for_delivery | en          | en      | True      | 0          | You can't cancel or refuse an order once it is...  |
| 14 | 8     | gpt-4o-mini | كم رسوم التوصيل داخل الأردن؟                   | rag                        | ar          | ar      | True      | 687        | رسوم التوصيل داخل الأردن هي 2 دينار أردني          |
| 15 | 8     | gpt-4o      | كم رسوم التوصيل داخل الأردن؟                   | rag                        | ar          | ar      | True      | 902        | رسوم التوصيل داخل الأردن هي 2 دينار أردني          |

## Latency and Policy Compliance Comparison

|   | model       | total | avg_latency_ms | policy_pass_rate | lang_pass_rate |
|---|-------------|-------|----------------|------------------|----------------|
| 0 | gpt-4o      | 15    | 846.933333     | 0.866667         | 0.933333       |
| 1 | gpt-4o-mini | 15    | 1019.266667    | 0.800000         | 0.866667       |

As shown in the table, GPT-4 achieved a lower average latency compared to GPT-4o Mini, meaning it generated responses slightly faster.

In addition, GPT-4 recorded a higher policy pass rate, which indicates stronger adherence to store policies such as return rules, cancellation constraints, and escalation conditions.

This suggests that GPT-4 is more reliable in policy-critical customer support scenarios.

|   |   |             |                                    |                    |    |    |      |       |      |                                                       |
|---|---|-------------|------------------------------------|--------------------|----|----|------|-------|------|-------------------------------------------------------|
| 4 | 3 | gpt-4o-mini | استلمت الطلب قبل 3 أيام ويدي أرجعه | after_48_no_return | ar | ar | True | False | 2644 | ...للإرجاع الطلب، يجب أن يتم ذلك خلال 48 ساعة من ا... |
| 5 | 3 | gpt-4o      | استلمت الطلب قبل 3 أيام ويدي أرجعه | after_48_no_return | ar | ar | True | True  | 2546 | للأسف، سياسة المتجر تلزم على أن الإرجاع مسموح...      |

Language Consistency Comparison

The results also show that GPT-4 had a higher language pass rate.

During testing, GPT-4o Mini occasionally responded in Arabic even when the user asked a question in English.

GPT-4 did not exhibit this behavior and consistently replied in the same language used by the customer.

This makes GPT-4 linguistically more stable and suitable for bilingual customer support.

|    |    |             |                                                  |     |    |    |       |      |      |                                                   |
|----|----|-------------|--------------------------------------------------|-----|----|----|-------|------|------|---------------------------------------------------|
| 18 | 10 | gpt-4o-mini | Can I change my delivery address after ordering? | rag | en | ar | False | True | 1094 | ...لتغيير عنوان التوصيل بعد إتمام الطلب ليس مسموح |
| 19 | 10 | gpt-4o      | Can I change my delivery address after ordering? | rag | en | en | True  | True | 1172 | Changing the delivery address after dispatch I... |

Hallucination Analysis

In the tested scenarios, neither GPT-4 nor GPT-4o Mini showed hallucination behavior.

Both models relied on the provided retrieval documents and predefined policies, and did not invent unsupported facts or policies.

This confirms that the RAG setup and prompt constraints were effective in grounding the models' responses.

|    |    |             |                                 |     |    |    |       |      |      |                                                |
|----|----|-------------|---------------------------------|-----|----|----|-------|------|------|------------------------------------------------|
| 20 | 11 | gpt-4o-mini | كيف أطلب من الموقع؟             | rag | ar | ar | True  | True | 746  | لا تتوفر لدي معلومات كافية حول هذا الموضوع حال |
| 21 | 11 | gpt-4o      | كيف أطلب من الموقع؟             | rag | ar | ar | True  | True | 576  | لا تتوفر لدي معلومات كافية حول هذا الموضوع حال |
| 22 | 12 | gpt-4o-mini | Can I order without an account? | rag | en | ar | False | True | 652  | لا تتوفر لدي معلومات كافية حول هذا الموضوع حال |
| 23 | 12 | gpt-4o      | Can I order without an account? | rag | en | ar | False | True | 1082 | لا تتوفر لدي معلومات كافية حول هذا الموضوع حال |

## Overall Observation

Overall, while GPT-4o Mini offers reasonable performance at a lower cost, GPT-4 proved to be superior in terms of response consistency, policy compliance, and language accuracy.

For this project, GPT-4 was selected as the final generation model due to its higher reliability in customer-facing scenarios.